



Estatística e Probabilidade

Aula 1 - Inferência Estatística

Professor: Josceli Tenório

Estimadores

A inferência estatística é quase sempre direcionada à obtenção de algum tipo de conclusão sobre um ou mais (características da população). O processo requer que o pesquisador obtenha dados de amostras de cada população em estudo. As conclusões baseiam-se, então, nos valores calculados das várias quantidades da amostra. Por exemplo: seja μ (um parâmetro) a tensão média de quebra real das conexões do fio usado na união de semicondutores. Uma amostra aleatória de $n = 10$ conexões pode ser feita e a tensão de quebra determinada, resultando em tensões observadas $x_1, x_2, \dots, x_n$. A tensão média de quebra da amostra $x_{\text{média}}$ usada para tirar conclusões sobre o valor de μ . De forma semelhante, se σ^2 for a variância da distribuição da tensão de quebra (variância da população, outro parâmetro), o valor da variância da amostra s^2 é inferir alguma coisa sobre σ^2 .

Mas qual estimador e estimativa usar?

Supondo que o estimador seja o valor médio dos dados, a estimativa correta será obtida por qual meio? (média, mediana, a média entre os valores extremos, média aparada)?

Um estimador preciso seria aquele que resultasse em pequenos erros de estimativa, de modo que os valores estimados estivessem próximos do valor real. Um estimador que possui as propriedades de não-tendenciosidade (se sua distribuição de probabilidade estiver sempre

"centrada" no valor real do parâmetro) e variância mínima geralmente será preciso nesse sentido.




Figura 1. As fdps de um estimador tendencioso $\hat{\theta}_1$, e um estimador não-tendencioso $\hat{\theta}_2$, para o parâmetro θ .

Além de relatar o valor de uma estimativa pontual, deve-se indicar a sua precisão. A medida comum de precisão é o erro-padrão do estimador usado.

Assumindo uma distribuição normal, $\bar{x} = x_{\text{médio}}$ é o melhor estimador de μ . Se o valor de σ for conhecido, o erro-padrão é:

$$\sigma_{\bar{x}} = \sigma/\sqrt{n}$$

Se extrairmos várias amostras de mesmo tamanho de uma população de indivíduos, qual é a medida de variabilidade de uma amostra para outra?

Se uma nova amostra aleatória for realizada, a média aritmética obtida será diferente da primeira amostra. A variabilidade das médias é estimada pelo seu erro padrão. Assim, o erro padrão avalia a precisão do cálculo da média populacional.

Resumindo:

Desvio-padrão: medida de variabilidade individual

Erro-padrão: é a medida de variabilidade entre amostras (precisão da estimativa).

Métodos de Estimativa Pontual

1. **Método dos momentos:** Deve-se igualar certas características da amostra, como a média, aos valores esperados correspondentes da população. As equações para os valores dos parâmetros desconhecidos produzem os estimadores.
2. **Método da máxima verossimilhança:** deve-se obter a estimativa mais verossímil dentro de uma amostra para o parâmetro populacional desconhecido.

Intervalos de confiança (IC)

Uma estimativa pontual, por ser um único número, não fornece por si mesma qualquer informação sobre a precisão e a confiabilidade da estimativa. Considere, por exemplo, o uso da estatística $X_{\text{médio}}$ para calcular a estimativa pontual de um conjunto de dados. Devido à variabilidade da amostragem, virtualmente nunca é o caso de $x_{\text{médio}} = \mu$. A estimativa pontual não diz nada sobre o quanto pode estar próxima de μ . Uma alternativa para apresentar um único valor sensato para o parâmetro que está sendo estimado é calcular e relatar um intervalo completo de valores plausíveis - uma estimativa de intervalo ou intervalo de confiança (IC).

Propriedades Básicas de Intervalos de Confiança

Os conceitos básicos e as propriedades dos intervalos de confiança (ICs) são introduzidos mais facilmente focando primeiro uma situação de problema simples, embora um pouco irreal. Suponha que o parâmetro de interesse seja a média de uma população μ e que:

1. A distribuição da população é normal.
2. O valor do desvio padrão da população σ é conhecido

Independentemente do tamanho da amostra n , a média amostral $X_{\text{médio}}$ é normalmente distribuída com valor esperado μ e desvio padrão:

$$\sigma/\sqrt{n}$$

Considerando a distribuição normal padrão Z :

$$Z = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}}$$

Em virtude de a área sob a curva normal padrão entre - 1,96 e 1,96 ser 0,95:

$$P\left(-1,96 < \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} < 1,96\right) = 0,95$$

O IC pode ser expresso como:

$$\left(\bar{x} - 1,96 \cdot \frac{\sigma}{\sqrt{n}}, \bar{x} + 1,96 \cdot \frac{\sigma}{\sqrt{n}}\right) \text{ é um IC de 95\% de } \mu$$

ou como:

$$\bar{x} - 1,96 \cdot \frac{\sigma}{\sqrt{n}} < \mu < \bar{x} + 1,96 \cdot \frac{\sigma}{\sqrt{n}} \text{ com 95\% de confiança}$$

A interpretação correta da "confiança de 95%" baseia-se na interpretação de frequência relativa de longo prazo da probabilidade: dizer que um evento A tem probabilidade de 0,95 significa dizer que, se o experimento no qual A é definido for repetido várias vezes, em longo prazo, A ocorrerá 95% das vezes.

Suponha que tenhamos uma amostra das alturas dos estudantes. Suponha que obtenhamos outra amostra e calculemos outro intervalo de 95%. Então, consideramos repetir o experimento para uma terceira amostra, para uma quarta e assim por diante, sabemos que 95% nossos ICs calculados conterão μ .

Intervalos Baseados em uma Distribuição Normal da População

O IC de μ apresentado é válido, desde que n seja grande. O intervalo resultante é usado, qualquer que seja a natureza da distribuição da população. E se o n for pequeno? Neste caso o Teorema do Limite Central não poderá ser usado. Uma maneira de continuar é fazer uma suposição específica sobre a forma da distribuição da população e deduzir um IC feito sob medida a essa suposição. Nessa situação, utilizamos a distribuição t.

Teorema

Quando $\bar{X}$ é a média amostral aleatória de tamanho n de uma distribuição normal com média μ , a va

$$T = \frac{\bar{X} - \mu}{S/\sqrt{n}} \quad (7.13)$$

possui uma distribuição de probabilidade chamada distribuição t com $n - 1$ graus de liberdade (gl).

A distribuição t é determinada apenas por um parâmetro, chamado número de graus de liberdade da distribuição, abreviado por gl. Na distribuição t o gl é representado pelo n da amostra. À medida que o tamanho amostral (n) aumenta, o número de graus de liberdade também aumenta e a distribuição t se aproxima de uma distribuição normal.

Propriedades das distribuições t :

Seja t_v a curva da função densidade dos gl de um parâmetro v .

1. Cada curva t_v possui formato de sino e está centrada em 0.
2. Toda curva t_v é mais dispersa que a curva normal padronizada (z).
3. À medida que v aumenta, a dispersão da curva t_v correspondente diminui.
4. À medida que $v \rightarrow \infty$ a sequência das curvas t_v se aproxima da curva normal padronizada (de modo que a curva z é chamada geralmente de curva t com $gl = \infty$).

Considerando a distribuição t (para a média), o IC é calculado por:

$$IC(\mu) = \left[\bar{x} - t \frac{S}{\sqrt{n}} ; \bar{x} + t \frac{S}{\sqrt{n}} \right]$$

onde μ é a média populacional;

$\bar{x}$ é a média amostral;

S é o desvio - padrão amostral;

t é a constante obtida da distribuição

t - Student com $(n - 1)$ graus de liberdade.

Intervalos de Confiança para Variância e Desvio Padrão de uma População Normal

Embora as inferências relacionadas à variância de uma população ou ao desvio padrão sejam geralmente de menor interesse que as referentes à média ou proporção, há ocasiões em que tais procedimentos são necessários. No caso de uma distribuição normal da população, as inferências são feitas com base no seguinte resultado relacionado à variância da amostra S^2 .

Teorema

Seja $X_1, X_2, \dots, X_n$ a amostra aleatória de uma distribuição normal com parâmetros μ e σ^2 . Então, a va

$$\frac{(n-1)S^2}{\sigma^2} = \frac{\sum (X_i - \bar{X})^2}{\sigma^2}$$

possui distribuição de probabilidade qui-quadrada (χ^2) com $n - 1$ gl.

Aplicações

1. Em uma pesquisa sobre a relação da prática de atividade física no colesterol total de indivíduos saudáveis, o que se pode afirmar sobre as populações investigadas com os dados amostrais a seguir?

Medidas-resumo do colesterol total (mg/dL)
dos indivíduos, segundo atividade física.

medidas-resumo	prática de atividade física	
	sim	não
n	100	100
média	200,0	209,8
variância	24,4	24,5
desvio-padrão	4,93	4,95
erro-padrão	0,49	0,50

[Ver o Código Python no Colab](#)

R.: Como não há superposição dos intervalos de confiança, conclui-se que o nível de colesterol total está relacionado à prática atividade física: quem não pratica atividade física tem maior colesterol quando comparado a quem pratica.

2. Se a média de IMC (Kg/m²) de uma determinada amostra de tamanho 30 é 25,4 kg/m² e o desvio-padrão é 6,0 kg/m². O que se pode afirmar sobre o IMC médio da população (μ) a um nível de 95% de confiança?

Supondo o desvio padrão populacional desconhecido, calcule o IC.

*Intervalo de confiança
para uma média*

$$IC(\mu) = \left[\bar{x} - t \frac{S}{\sqrt{n}} ; \bar{x} + t \frac{S}{\sqrt{n}} \right]$$

onde μ é a média populacional;

$\bar{x}$ é a média amostral;

S é o desvio - padrão amostral;

t é a constante obtida da distribuição

t - Student com (n - 1) graus de liberdade.

[Ver o Código Python no Colab](#)

3. Uma pesquisa investigou 100 indivíduos, sendo 50 do grupo doente e 50 do grupo controle. A proporção (porcentagem) de fadiga, segundo determinada escala validada para a população estudada, foi medida e comparada entre os grupos. No grupo doente houveram 35 pacientes com fadiga. No grupo controle houveram 15 pacientes com fadiga.

Como seria o intervalo para cada uma das proporções consideradas?


Faça o código em R.

**Intervalo de confiança
para uma proporção**

$$IC(p) = \left[\hat{p} - c \sqrt{\frac{\hat{p}(1-\hat{p})}{n}} ; \hat{p} + c \sqrt{\frac{\hat{p}(1-\hat{p})}{n}} \right]$$

onde p = proporção populacional;
 $\hat{p}$ é a proporção amostral.

c é obtido da Distribuição Normal Padrão.



4. Considere a quantidade de placa bacteriana antes e depois do tratamento.

- Faça o boxplot dos dados antes e depois do tratamento
- Construa o histograma para antes e depois.
- A distribuição é normal?
- Podemos afirmar que com IC=95% que há diferença na quantidade de placa bacteriana antes e depois?

Para construir a tabela (dataframe) no Python:

```
antes: [2.18, 2.05, 1.05, 1.95, 0.28, 2.63, 1.5, 0.45, 0.7, 1.3, 1.25, 0.18,
3.3, 1.4, 0.9, 0.58, 2.5, 2.25, 1.53, 1.43, 3.48, 1.8, 1.5, 2.55, 1.3, 2.65],
```

```
depois: [0.43, 0.08, 0.18, 0.78, 0.03, 0.23, 0.2, 0.0, 0.05, 0.3, 0.33, 0.0,  
0.9, 0.24, 0.15, 0.1, 0.33, 0.33, 0.53, 0.43, 0.65, 0.2, 0.25, 0.15, 0.05,  
0.25]
```

Referência

Devore J L. Probability and Statistics for Engineering and the Sciences. Thomson ed. 5a. ed. 284 p.

Minitab. Disponível em

<https://blog.minitab.com/pt/quais-sao-os-graus-de-liberdade-nas-estatisticas>

