



Estatística e Probabilidade

Aula 4 - Análise bivariada

Professora: Josceli Tenório

Introdução

Como calcular a frequência em análise com duas variáveis? Qual o total utilizar? Da coluna? Da linha? Ou o total geral?

Depende da análise desejada. A divisão pelo total geral expressa a composição do grupo por ambas características. A divisão pelo total da linha ou da coluna expressa um resultado condicionado à observação da linha ou coluna. A Figura 1 mostra um exemplo relacionando as variáveis grau de instrução (Y) e região de procedência (V). Verifique que os totais foram apresentados. É a denominada tabela de contingência.

	Ensino Fundamental	Ensino Médio	Superior	Total
Capital	4	5	2	11
Interior	3	7	2	12
Outro	5	6	2	13
Total	12	18	6	36

Figura 1. Tabela de contingência: distribuição das frequências absolutas entre as variáveis Y e V.

A Figura 2 mostra a análise pela frequência relativa (proporção) das observações em relação ao total.

	Ensino Fundamental	Ensino Médio	Superior
Capital	0.1111	0.1389	0.0556
Interior	0.0833	0.1944	0.0556
Outro	0.1389	0.1667	0.0556

Figura 2. Tabela de contingência: frequência das observações em relação ao total da amostra em %.

A Figura 3 mostra a frequência relativa (proporção) considerando o total por linha e por coluna.

Por linha:

	Ensino Fundamental	Ensino Médio	Superior
Capital	0.3636	0.4545	0.1818
Interior	0.2500	0.5833	0.1667
Outro	0.3846	0.4615	0.1538

Por coluna:

	Ensino Fundamental	Ensino Médio	Superior
Capital	0.3333	0.2778	0.3333
Interior	0.2500	0.3889	0.3333
Outro	0.4167	0.3333	0.3333

Figura 3. Análises pelo total da linha e da coluna amostra.

O que dizem os dados?

No exemplo, a distribuição pelo total das linhas mostra que, por exemplo, 36% dos funcionários da empresa que vieram da capital, terminaram o ensino fundamental.

Por outro lado, no exemplo da divisão pelos totais das colunas, temos que entre os funcionários com ensino médio, 39% vieram do interior.

A Figura 4 mostra as relações entre Y e V.




Figura 4. Distribuição do grau de instrução por região de procedência (em %).

Calcular o índice de associação (coeficiente de contingência de Pearson, (C))

O coeficiente de contingência é dado por:

$$C = \sqrt{\frac{\chi^2}{n + \chi^2}}$$

onde χ^2 é o valor do qui-quadrado e (n) é o total de observações (36).

Cálculo de χ^2 :

O χ^2 é calculado como:

$$\chi^2 = \sum \frac{(O_i - E_i)^2}{E_i}$$

onde O_i é a frequência observada e E_i é a frequência esperada.

Frequências esperadas:

- $E_{11} = \frac{11 \times 12}{36} = 3.67$ (Capital, Ensino Fundamental)
- $E_{12} = \frac{11 \times 18}{36} = 5.5$ (Capital, Ensino Médio)
- $E_{13} = \frac{11 \times 6}{36} = 1.83$ (Capital, Superior)
- $E_{21} = \frac{12 \times 12}{36} = 4$ (Interior, Ensino Fundamental)
- $E_{22} = \frac{12 \times 18}{36} = 6$ (Interior, Ensino Médio)
- $E_{23} = \frac{12 \times 6}{36} = 2$ (Interior, Superior)
- $E_{31} = \frac{13 \times 12}{36} = 4.33$ (Outro, Ensino Fundamental)
- $E_{32} = \frac{13 \times 18}{36} = 6.5$ (Outro, Ensino Médio)
- $E_{33} = \frac{13 \times 6}{36} = 2.17$ (Outro, Superior)

Cálculo de χ^2 :

- $\frac{(4 - 3.67)^2}{3.67} = \frac{0.33^2}{3.67} \approx 0.03$
- $\frac{(5 - 5.5)^2}{5.5} = \frac{0.5^2}{5.5} \approx 0.05$
- $\frac{(2 - 1.83)^2}{1.83} = \frac{0.17^2}{1.83} \approx 0.02$
- $\frac{(3 - 4)^2}{4} = \frac{(-1)^2}{4} = 0.25$
- $\frac{(7 - 6)^2}{6} = \frac{1^2}{6} \approx 0.17$
- $\frac{(2 - 2)^2}{2} = 0$
- $\frac{(5 - 4.33)^2}{4.33} = \frac{0.67^2}{4.33} \approx 0.10$
- $\frac{(6 - 6.5)^2}{6.5} = \frac{0.5^2}{6.5} \approx 0.04$
- $\frac{(2 - 2.17)^2}{2.17} = \frac{0.17^2}{2.17} \approx 0.01$

$$\chi^2 \approx 0.03 + 0.05 + 0.02 + 0.25 + 0.17 + 0 + 0.10 + 0.04 + 0.01 \approx 0.67$$

Coefficiente de contingência:

$$C = \sqrt{\frac{\chi^2}{n + \chi^2}} = \sqrt{\frac{0.67}{36 + 0.67}} = \sqrt{\frac{0.67}{36.67}} \approx \sqrt{0.0183} \approx 0.135$$

A associação entre localidade e nível de ensino é fraca ($C = 0.135$), sugerindo que a localidade tem pouca influência sobre o nível de escolaridade com base nesses dados.

Associação entre variáveis


O objetivo de estabelecer a distribuição conjunta de duas variáveis é o de compreender a existência de alguma associação entre elas, ou o grau de dependência entre elas.

Associação entre variáveis quantitativas

Exemplo: Há alguma relação entre o número de clientes e os anos de serviço prestados pela empresa?

Tabela 1. Número de clientes e serviços prestados.

Agente	Anos de serviço (X)	Número de clientes
A	2	48
B	3	50
C	4	56
D	5	52
E	4	43
F	6	60
G	7	62
H	8	58
I	8	64
J	10	72



Por meio do gráfico de dispersão verificam-se possíveis relações entre duas variáveis numéricas.

Covariância

Dados n pares de valores $(x_1, y_1) \dots, (x_n, y_n)$, chamaremos de covariância entre as variáveis X e Y , consideradas como população:

$$\text{cov}(X, Y) = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{n}$$

Vamos denominar a $\text{cov}(X, Y)$ como s_{xy} .

Ao considerar dados amostrais, a mesma correção aplicada ao cálculo da variância é utilizada e o denominador deverá ser $n-1$.

Se as variáveis estiverem correlacionadas de alguma forma, sua covariância será diferente de zero. De fato, se $\text{cov}(X, Y) > 0$, então Y tende a aumentar à medida que X aumenta, e se $\text{cov}(X, Y) < 0$, então Y tende a diminuir à medida que X aumenta. Observe que, embora as variáveis estatisticamente independentes sejam sempre não correlacionadas, a recíproca não é necessariamente verdadeira.

A covariância é a medida do afastamento simultâneo das respectivas médias.

Se as ambas variáveis aleatórias tendem a estar simultaneamente acima, ou abaixo, de suas respectivas médias, então a covariância tenderá a ser positiva e nos outros casos poderá ser negativa, como mostram os gráficos abaixo.

Características da covariância

A covariância de uma variável e ela mesma é a própria variância da variável, seja no caso de população ou amostra. Como $Y = X$, s_{xy} será:

$$\frac{\sum_{i=1}^N (X_i - \mu_X) \times (X_i - \mu_X)}{N} = \frac{\sum_{i=1}^N (X_i - \mu_X)^2}{N} ;$$

Dessa forma teremos $s_{xy} = s_{xx}^2$

A permutação das variáveis não altera o resultado da covariância, se os pares de valores não forem alterados: $s_{xy} = s_{yx}$

Da mesma forma que a variância, a covariância é afetada pelos valores extremos da variável, ela não é uma medida resistente.

A unidade de medida é o resultado do produto das unidades dos valores das variáveis.

Coeficiente de correlação

Para facilitar o entendimento da relação entre duas variáveis e evitar a unidade de medida da covariância, foi definido o coeficiente de correlação r_{xy} .

Os valores de r_{xy} estão limitados entre os valores -1 e +1, e sem nenhuma unidade de medida.

O coeficiente de correlação busca auferir a direção da relação entre as variáveis, dentro de um intervalo determinado entre -1 e 1.

O objetivo do intervalo é discriminar a direção e a intensidade da relação:

- valores próximos de zero indicam ausência de relação entre as variáveis.
- valores próximos de 1 indicam forte relação positiva.
- valores próximos de -1 indicam forte relação negativa.

Um dos coeficientes de correlação mais conhecidos é o coeficiente de correlação de Pearson, porém sensível a uma relação linear entre duas variáveis. A relação que possibilita calcular o coeficiente de correlação amostral de Pearson entre as variáveis é:

r: Coeficiente de correlação amostral

$$r = \frac{1}{n-1} \sum_{i=1}^n \left(\frac{x_i - \bar{x}}{s_x} \right) \left(\frac{y_i - \bar{y}}{s_y} \right)$$

onde :

$$s_x = \sqrt{\frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n-1}} \quad s_y = \sqrt{\frac{\sum_{i=1}^n (y_i - \bar{y})^2}{n-1}}$$

são os desvios - padrão da variável x e y, respectivamente.

Se definirmos:

$$S_{xx} = \sum_{i=1}^n (x_i - \bar{x})^2 = (n-1) s_x^2$$

$$S_{yy} = \sum_{i=1}^n (y_i - \bar{y})^2 = (n-1) s_y^2$$

$$S_{xy} = \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$$

De forma simplificada, podemos escrever:

$$r = \frac{S_{xy}}{\sqrt{S_{xx}} \sqrt{S_{yy}}}$$

Há outros coeficientes de correlação mais robustos que o coeficiente de correlação de Pearson. Isto é, mais sensíveis às relações não lineares.

Exemplo: Utilizando a tabela anterior e considerando como dados populacionais (n=10).

Agente	Anos de serviço (X)	Número de clientes	$x - \bar{x}$	$y - \bar{y}$	$\frac{x - \bar{x}}{dp(X)} = z_x$	$\frac{y - \bar{y}}{dp(Y)} = z_y$
A	2	48	-3,7	-8,5	-1,54	-1,05
B	3	50	-2,7	-6,5	-1,12	-0,80
C	4	56	-1,7	-0,5	-0,71	-0,06
D	5	52	-0,7	-4,5	-0,29	-0,55
E	4	43	-1,7	-13,5	-0,71	-1,66
F	6	60	0,3	3,5	0,12	0,43
G	7	62	1,3	5,5	0,54	0,68
H	8	58	2,3	1,5	0,95	0,18
I	8	64	2,3	7,5	0,95	0,92
J	10	72	4,3	15,5	1,78	1,91

Média: $x = 5,7$ e $y = 56,5$


$$s_x^2 = 58,1/10 = 5,81 \Rightarrow s_x = \sqrt{5,81} = 2,41$$

$$s_y^2 = 658,5/10 = 65,85 \Rightarrow s_y = \sqrt{65,85} = 8,11$$

O coeficiente de correlação é:

$$r_{xy} = 8,77/10 = 0,877$$

Se existe correlação significativa e razões para usar uma variável para prever a outra, qual a equação da reta que melhor se ajusta ao gráfico de dispersão?



$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$$

Como obter os coeficientes a partir dos dados amostrais?

Melhor ajuste: **método dos mínimos quadrados.**

Minimiza-se a soma das distâncias verticais entre um ponto amostral e a reta procurada.

$$\sum_{i=1}^n (y_i - \hat{y}_i)^2 = \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i)^2$$

Solução:

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$$

$$\hat{\beta}_1 = \frac{s_{xy}}{s_{xx}} = \frac{\sum (x - \bar{x})(y - \bar{y})}{\sum (x - \bar{x})^2}$$

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

Exemplo:

receita	vendas
131	23
120	24
140	26
151	29
160	33
167	38
185	41
170	42
188	50
195	55
200	60



Observa-se uma relação aproximadamente linear entre as variáveis.

Para obter a reta ajustada precisamos calcular os coeficientes linear e angular:

$$\bar{x} = \sum x_i / n = 421 / 11 = 38.2727$$

$$\bar{y} = \sum y_i / n = 1807 / 11 = 164.2727$$

$$S_{xx} = \sum (x_i - \bar{x})^2 = 1612.182$$

$$S_{yy} = \sum (y_i - \bar{y})^2 = 7104.182$$

$$S_{xy} = \sum (x_i - \bar{x})(y_i - \bar{y}) = 3229.182$$

Temos :

$$r = \frac{3229,0}{\sqrt{1612,18 \times 7104,18}}$$


$$r \approx \frac{3229,0}{3385,3}$$

$$r \approx 0,95$$

$$\beta_1 = S_{xy} / S_{xx} = 3229.182 / 1612.182 = 2.003$$

$$\beta_0 = \bar{y} - \beta_1 \bar{x} = 87.613$$

A reta ajustada será:



$$y = 2.003x + 87.613$$

Cuidado!!!


O coeficiente de correlação não mede a relação causa efeito entre as variáveis, apesar de que essa relação possa estar presente.

Uma correlação fortemente positiva entre as variáveis X e Y não autoriza afirmar que variações da variável X provocam variações na variável Y, ou vice-versa.


O coeficiente de correlação sozinho não identifica a relação causa-efeito entre as duas variáveis

Exemplos de anomalias

Para r próximo a + 1



Para r próximo a 0.



Aplicações

1. Uma pesquisa foi realizada para investigar a relação entre o nível de escolaridade e o hábito de leitura de livros por semana. Os dados coletados de 200 pessoas foram organizados na seguinte tabela de contingência:

Nível de Escolaridade	Lê 0-1 Livro	Lê 2-3 Livros	Lê 4+ Livros	Total
Fundamental	40	15	5	60
Médio	30	25	10	65
Superior	20	30	25	75
Total	90	70	40	200

- Calcule as frequências relativas por linha (percentual de cada categoria de leitura dentro de cada nível de escolaridade).
- Calcule as frequências relativas por coluna (percentual de cada nível de escolaridade dentro de cada categoria de leitura).
- Determine o total de frequências relativas (deve somar 100% para verificar a consistência).
- Calcule o índice de associação (usando o coeficiente de contingência de Pearson, (C)) para avaliar a relação entre o nível de escolaridade e o hábito de leitura. A fórmula é:

$$C = \sqrt{\frac{\chi^2}{n + \chi^2}}$$

onde χ^2 é o qui-quadrado e (n) é o total de observações (200). Para simplificar, use a aproximação do χ^2 com base nas diferenças entre frequências observadas e esperadas (pode ser estimado manualmente ou deixado como passo para cálculo detalhado).

- Interprete os resultados: há alguma associação entre o nível de escolaridade e o hábito de leitura?

- f) Compare as frequências observadas com as esperadas para estimar a associação.

Dica:

- Para o χ^2 , as frequências esperadas podem ser calculadas como

$$\frac{(\text{linha total}) \times (\text{coluna total})}{\text{total geral}}.$$

- Por exemplo, para "Fundamental" e "0-1 Livro":

$$\text{"Fundamental" e "0-1 Livro": } \frac{60 \times 90}{200} = 27.$$

2. Considere os seguintes dados que relacionam o número de horas estudadas (x) e as notas obtidas (y) por 8 alunos:

Aluno	x_i	y_i	$(x_i - \bar{x})$	$(y_i - \bar{y})$	$(x_i - \bar{x})^2$	$(y_i - \bar{y})^2$	$(x_i - \bar{x})(y_i - \bar{y})$
1	2	50	-3.5	-17.5	12.25	306.25	61.25
2	3	55	-2.5	-12.5	6.25	156.25	31.25
3	4	60	-1.5	-7.5	2.25	56.25	11.25
4	5	65	-0.5	-2.5	0.25	6.25	1.25
5	6	70	0.5	2.5	0.25	6.25	1.25
6	7	75	1.5	7.5	2.25	56.25	11.25
7	8	80	2.5	12.5	6.25	156.25	31.25
8	9	85	3.5	17.5	12.25	306.25	61.25

- a) Calcule a média de x ($\bar{x}$) e a média de y ($\bar{y}$).
 b) Use os resultados da tabela para calcular:

- $S_{xx} = \sum (x_i - \bar{x})^2$
 - $S_{yy} = \sum (y_i - \bar{y})^2$
 - $S_{xy} = \sum (x_i - \bar{x})(y_i - \bar{y})$
- c) Calcule o coeficiente de correlação de Pearson
- d) Determine os coeficientes da reta de regressão $y = \beta_0 + \beta_1 x$:
- e) Escreva a equação da reta de regressão.

