



Estatística e Probabilidade

Aula 3 - Probabilidade

Professora: Josceli Tenório

Distribuições de Probabilidade

Independentemente de um experimento gerar resultados quantitativos ou qualitativos, os métodos de análise estatística requerem que sejam enfocados certos aspectos numéricos dos dados (como proporção de amostra x/n , média $\bar{x}$ e desvio padrão (s)). O conceito de variável aleatória nos permite passar dos resultados do experimento propriamente ditos para uma função numérica dos resultados. Há dois tipos fundamentalmente diferentes de variáveis aleatórias: variáveis aleatórias discretas e variáveis aleatórias contínuas.

Em qualquer experimento há diversas características que podem ser observadas ou medidas, mas na maioria dos casos o experimento enfocará um ou alguns aspectos específicos da amostra. Em geral, cada resultado de um experimento é associado a um número, especificando-se uma regra de associação (por exemplo: a quantidade de componentes que apresentam falha em um período de mil horas em uma amostra de 10 componentes ou o peso total de bagagem para uma amostra de 25 passageiros de uma companhia aérea). Tal regra de associação é denominada variável aleatória. Variável porque é possível obter diferentes valores numéricos, e aleatória porque o valor observado depende de qual dos resultados possíveis do experimento é obtido.

Definição

Para um dado espaço amostral S de um experimento, uma variável aleatória (va) é qualquer regra que associe um valor a cada resultado de S . Em termos matemáticos, uma variável aleatória é uma função cujo domínio é o espaço amostral e o contra-domínio é um conjunto de números reais.

Exemplo

Quando um estudante tenta acessar um computador em um sistema de compartilhamento de tempo, todas as portas estão ocupadas (F), caso em que o aluno não terá sucesso, ou haverá ao menos uma porta livre (L), caso em que o estudante conseguirá acessar o sistema.

Com $S = \{L, F\}$, defina uma va X como

$$X(L) = 1 \quad X(F) = 0$$

A va X indica se o estudante pode (1) ou não (0) acessá-lo.

Tipos de variáveis aleatórias

Definição

Uma variável aleatória **discreta** é uma variável, cujos valores possíveis constituem um conjunto finito ou podem ser relacionados em uma sequência infinita na qual haja um primeiro elemento, um segundo e assim por diante. Uma variável aleatória é **contínua** se seu conjunto de valores possíveis consiste em um intervalo completo da reta de números (reta real).

Distribuições de Probabilidade para Variáveis Aleatórias Discretas

Quando são atribuídas probabilidades a diversos resultados de , elas, por sua vez, determinam probabilidades associadas aos valores de qualquer va X em particular. A distribuição de probabilidade de X expressa como a probabilidade total 1 é distribuída (alocada a) entre os diversos valores possíveis de X .

Exemplo

Seis lotes de componentes estão prontos para embarque em um fornecedor. O número de componentes com defeito em cada lote é mostrado a seguir:

<i>Lote</i>	1	2	3	4	5	6
<i>Número de peças com defeito</i>	0	2	0	1	2	0

Um desses lotes será selecionado aleatoriamente para embarque a um cliente específico. Seja X o número de peças com defeito no lote selecionado. Os três valores possíveis de X são 0, 1 e 2. Dos seis eventos igualmente prováveis, três resultam em $X = 0$, um em $X = 1$ e os outros dois em $X = 2$. Sejam $p(0)$ a probabilidade de $X = 0$ e $p(1)$ e $p(2)$ as probabilidades dos outros dois valores possíveis de X . Então

$$p(0) = P(X = 0) = P(\text{lote 1 ou 3 ou 6 é enviado}) = \frac{3}{6} = 0,500$$

$$p(1) = P(X = 1) = P(\text{lote 4 é enviado}) = \frac{1}{6} = 0,167$$

$$p(2) = P(X = 2) = P(\text{lote 2 ou 5 é enviado}) = \frac{2}{6} = 0,333$$

Os valores de X juntamente com suas probabilidades especificam coletivamente a distribuição de probabilidade ou função de massa da probabilidade de X . Se o experimento fosse repetido diversas vezes no longo prazo, $X = 0$ ocorreria na metade das vezes, $X = 1$ em um sexto das vezes e $X = 2$ em um terço das vezes.

Definição

A função distribuição de probabilidade ou função de massa de probabilidade (fmp) de uma variável discreta é definida para cada número x por $p(x) = P(X = x) = P(\text{todos os } s \in S : X(s) = x)$.

Função Distribuição Acumulada

Definição

A **função de distribuição acumulada** (FDA) $F(x)$ de uma variável aleatória discreta X com fmp $p(x)$ é definida para cada valor de x por

$$F(x) = P(X \leq x) = \sum_{y: y \leq x} p(y)$$

Para qualquer valor x , $F(x)$ é a probabilidade de o valor X observado ser no máximo x

Considere um grupo de cinco doadores de sangue potenciais: A, B, C, D e E. Desses, apenas A e B possuem o tipo O+. Cinco amostras de sangue, uma de cada indivíduo, serão testadas em ordem aleatória até que seja identificado um indivíduo O+. Seja a v.a. Y = número de testes necessários para identificar um indivíduo O+. Então a fmp de Y é:

$$p(1) = P(Y = 1) = P(\text{A ou B identificados primeiro}) = \frac{2}{5} = 0,4$$

$$p(2) = P(Y = 2) = P(\text{C, D, ou E primeiro e então A ou B})$$

$$= P(\text{C, D, ou E primeiro}) \cdot P(\text{A ou B depois} \mid \text{C, D ou E primeiro}) = \frac{3}{5} \cdot \frac{2}{4} = 0,3$$

$$p(3) = P(Y = 3) = P(\text{C, D, ou E primeiro e segundo, então A ou B})$$

$$= \left(\frac{3}{5}\right)\left(\frac{2}{4}\right)\left(\frac{2}{3}\right) = 0,2$$

$$p(4) = P(Y = 4) = P(\text{C, D, e E, todos feitos primeiro}) = \left(\frac{3}{5}\right)\left(\frac{2}{4}\right)\left(\frac{1}{3}\right) = 0,1$$

$$p(y) = 0 \quad \text{se } y \neq 1, 2, 3, 4$$

A fmp pode ser melhor apresentada na forma tabular:

y	1	2	3	4
p(y)	0,4	0,3	0,2	0,1

Vamos determinar $F(y)$ para cada valor do conjunto $\{1, 2, 3, 4\}$ de valores possíveis:

$$F(1) = P(Y \leq 1) = P(Y = 1) = p(1) = 0,4$$

$$F(2) = P(Y \leq 2) = P(Y = 1 \text{ ou } 2) = p(1) + p(2) = 0,7$$

$$F(3) = P(Y \leq 3) = P(Y = 1 \text{ ou } 2 \text{ ou } 3) = p(1) + p(2) + p(3) = 0,9$$

$$F(4) = P(Y \leq 4) = P(Y = 1 \text{ ou } 2 \text{ ou } 3 \text{ ou } 4) = 1$$

A FDA será:

$$F(y) = \begin{cases} 0 & \text{se } y < 1 \\ 0,4 & \text{se } 1 \leq y < 2 \\ 0,7 & \text{se } 2 \leq y < 3 \\ 0,9 & \text{se } 3 \leq y < 4 \\ 1 & \text{se } 4 \leq y \end{cases}$$

O gráfico de $F(y)$ é denominado função degrau:



Distribuição de Probabilidade Binomial

Há diversos experimentos que satisfazem exatamente ou aproximadamente a seguinte lista de requisitos:

1. O experimento consiste em uma sequência de n experimentos menores denominados tentativas, onde n é estabelecido antes do experimento.
2. Cada tentativa pode resultar em um de dois resultados possíveis (tentativas dicotômicas), chamados de sucesso (S) ou falha (F).
3. As tentativas são independentes, de forma que o resultado de qualquer tentativa particular não influencia o resultado de qualquer outra tentativa.
4. A probabilidade de sucesso é constante de uma tentativa para a outra. Denominamos essa probabilidade p .

Um experimento para o qual as condições 1- 4 são satisfeitas é denominado **experimento binomial**.

Variável aleatória binomial e sua distribuição

Definição

Dado um experimento binomial consistindo de n tentativas, a variável aleatória binomial X a ele associada é definida como

X = quantidade de S nas n tentativas

Considere o caso de $n = 4$ para o qual cada resultado, sua probabilidade e o valor de x correspondente estão relacionados na Tabela 1. Por exemplo:

Tabela 1. Resultados e probabilidades de um experimento binomial com quatro tentativas.

Resultado	x	Probabilidade	Resultado	x	Probabilidade
<i>SSSS</i>	4	p^4	<i>FSSS</i>	3	$p^3(1-p)$
<i>SSSF</i>	3	$p^3(1-p)$	<i>FSSF</i>	2	$p^2(1-p)^2$
<i>SSFS</i>	3	$p^3(1-p)$	<i>FSFS</i>	2	$p^2(1-p)^2$
<i>SSFF</i>	2	$p^2(1-p)^2$	<i>FSFF</i>	1	$p(1-p)^3$
<i>SFSS</i>	3	$p^3(1-p)$	<i>FFSS</i>	2	$p^2(1-p)^2$
<i>SFSF</i>	2	$p^2(1-p)^2$	<i>FFSF</i>	1	$p(1-p)^3$
<i>SFFS</i>	2	$p^2(1-p)^2$	<i>FFFS</i>	1	$p(1-p)^3$
<i>SFFF</i>	1	$p(1-p)^3$	<i>FFFF</i>	0	$(1-p)^4$

Lembre-se: as tentativas são independentes.

Considerando o primeiro fator como o número de maneiras de escolher x das n tentativas serem S , isto é, o número de combinações de tamanho x que podem ser construídas com n objetos distintos (tentativas, no caso), chegaremos à relação:

Teorema

$$b(x; n, p) = \begin{cases} \binom{n}{x} p^x (1-p)^{n-x} & x = 0, 1, 2, \dots, n \\ 0 & \text{caso contrário} \end{cases}$$

Obs.: A relação acima pode ser escrita como:

$$\begin{aligned} Pr(x \text{ successes in } n \text{ trials}) = \\ \frac{n!}{x!(n-x)!} p^x (1-p)^{n-x}, \end{aligned}$$

Exemplo

Cada um de seis consumidores de refrigerante selecionados aleatoriamente recebe um copo com o refrigerante S e um com o refrigerante F. Os copos são idênticos, exceto por um código no fundo que identifica o refrigerante. Suponha que não haja uma tendência de preferência entre os consumidores. Então

$p = P(\text{um indivíduo selecionado prefere S}) = 0,5$, de forma que

$X = \text{número de consumidores entre os seis que preferem S}$, $X \sim \text{Bin}(6; 0,5)$ (lê-se X distribuída como).

Dessa forma, a probabilidade de três preferirem S é;

$$P(X = 3) = b(3; 6, 0,5) = \binom{6}{3}(0,5)^3(0,5)^3 = 20(0,5)^6 = 0,313$$

A probabilidade de pelo menos três preferirem S é

$$P(3 \leq X) = \sum_{x=3}^6 b(x; 6, 0,5) = \sum_{x=3}^6 \binom{6}{x}(0,5)^x(0,5)^{6-x} = 0,656$$

e a probabilidade de no máximo um preferir S é

$$P(X \leq 1) = \sum_{x=0}^1 b(x; 6, 0,5) = 0,109$$

Uso das tabelas binomiais

Suponha que 20% de todas as cópias de um livro-texto apresentem falha em um determinado teste de resistência de encadernação. Seja X o número de cópias que apresentam falhas entre 15 cópias selecionadas aleatoriamente. Então X tem distribuição binomial com $n = 15$ e $p = 0,2$.

A probabilidade de no máximo 8 apresentarem falha é

$$P(X \leq 8) = \sum_{y=0}^8 b(y; 15, 0,2) = B(8; 15, 0,2)$$

Pela tabela: $B(8; 15, 0,2) = 0,999$

A probabilidade de exatamente 8 apresentarem falha é

$$P(X = 8) = P(X \leq 8) - P(X \leq 7) = B(8; 15, 0,2) - B(7; 15, 0,2)$$

Pela tabela o resultado é $0,999 - 0,996 = 0,003$

A probabilidade de no mínimo 8 apresentarem falha é

$$P(X \geq 8) = 1 - P(X \leq 7) = 1 - B(7; 15, 0,2)$$

Pela tabela o resultado é: $1 - 0,996 = 0,004$

Exemplos de fenômenos modelados por distribuições binomial:

1. **Controle de Qualidade na Fabricação:** Uma fábrica produz lâmpadas, e cada lâmpada tem 2% de probabilidade de ser defeituosa. Se for coletada uma amostra aleatória de 100 lâmpadas, podemos usar a distribuição binomial para encontrar a probabilidade de um determinado número de lâmpadas defeituosas.
2. **Estatísticas Esportivas:** Em um jogo de basquete, um jogador tem uma taxa de sucesso de 80% nos lances livres. Durante uma partida, o jogador realiza 15 lances livres. Podemos usar a distribuição para calcular a probabilidade de acertar os 15 lances livres.

Distribuição hipergeométrica

A distribuição hipergeométrica é utilizada quando realizamos amostragens aleatórias sem reposição em uma população finita. Considere uma população com N elementos, dos quais r possuem uma determinada característica A (por exemplo, defeito) e $N - r$ não possuem essa característica.

Ao selecionar n elementos aleatoriamente, sem reposição, queremos determinar a probabilidade de obter k elementos com a característica A na amostra.

A função de probabilidade da variável aleatória X (número de elementos com característica A na amostra) é dada por:

$$p_k = \frac{\binom{r}{k} \binom{N-r}{n-k}}{\binom{N}{n}},$$

onde:

- N = tamanho da população
- r = número de elementos com a característica de interesse
- n = tamanho da amostra
- k = número de elementos com a característica na amostra

Os valores possíveis de k satisfazem:

$$\max(0, n - N + r) \leq k \leq \min(r, n)$$

A média (valor esperado) e a variância dessa distribuição são:

$$E(X) = n \frac{r}{N}$$

$$Var(X) = n \frac{r}{N} \left(1 - \frac{r}{N}\right) \frac{N-n}{N-1}$$

Em resumo, as hipóteses que levam à distribuição hipergeométrica são:

1. A população ou o conjunto de onde é retirada a amostra consiste de N indivíduos, objetos ou elementos (população finita).
2. Cada indivíduo é classificado como sucesso (S) ou falha (F) e há M sucessos na população.
3. É selecionada uma amostra sem reposição de n indivíduos de forma que cada subconjunto de tamanho n seja igualmente provável de ser escolhido.

A distribuição hipergeométrica aparece frequentemente em:

- detecção de falhas em redes
- amostragem de pacotes com erro
- avaliação de datasets rotulados

- testes de integridade de backups
- validação de registros em bancos de dados

Distribuição Binomial Negativa

A distribuição binomial negativa modela o número de tentativas necessárias até que ocorra um número fixo de sucessos em experimentos independentes, nos quais cada tentativa possui apenas dois resultados possíveis: sucesso ou fracasso.

Diferentemente da distribuição binomial, na qual o número de tentativas é fixo, na binomial negativa o número de sucessos desejados é fixado previamente, e a variável aleatória representa quantas tentativas são necessárias para atingir esse objetivo.

A função de probabilidade é:

$$P(X = k) = \binom{k-1}{r-1} p^r (1-p)^{k-r}$$

onde:

$$k = r, r + 1, r + 2, \dots$$

O valor esperado e a variância são dados por:

$$E(X) = \frac{r}{p}$$

$$Var(X) = \frac{r(1-p)}{p^2}$$

Sendo:

- p = probabilidade de sucesso em cada tentativa
- r = número de sucessos desejados
- k = número total de tentativas necessárias para obter os r sucessos
- X = número de tentativas até ocorrerem r sucessos

Em resumo, a distribuição binomial negativa são baseadas em experimentos que satisfaçam às condições a seguir:

1. O experimento consiste de uma sequência de tentativas independentes.
2. Cada tentativa resulta em sucesso (S) ou em falha (F).
3. A probabilidade de sucesso é constante de uma tentativa para outra, então $P(S \text{ na tentativa } i) = p$ para $i = 1, 2, 3, \dots$
4. O experimento continua (as tentativas são executadas) até ser observado um total de r sucessos, sendo r um inteiro positivo.

Distribuição de Poisson

As distribuições binomial, hipergeométrica e binomial negativa foram deduzidas a partir de um experimento consistindo de tentativas ou retiradas e na aplicação das leis da probabilidade aos diversos resultados do experimento. Não há um experimento simples que sirva de base para a distribuição de Poisson, apesar de descrevermos simplifadamente como ela pode ser obtida por meio de certas operações limitantes.

Definição

Uma variável aleatória X tem distribuição de Poisson com parâmetro λ ($\lambda > 0$) se a fmp de X for

$$p(x; \lambda) = \frac{e^{-\lambda} \lambda^x}{x!} \quad x = 0, 1, 2, \dots$$

Determinação de uma distribuição de Poisson

1. Identifique a variável aleatória X , que é igual ao número de sucessos no intervalo.
2. Determine o número médio λ de sucessos para uma específica dimensão de tempo ou espaço.
3. Utilize a fórmula

Exemplo

Seja X o número de certo tipo de animais capturados em uma armadilha durante certo período de tempo. Suponha que X tenha uma distribuição de Poisson com $\lambda = 4,5$, de forma que, em média, cada armadilha contém 4,5 animais.

A probabilidade de uma armadilha conter exatamente cinco animais é:

$$P(X = 5) = \frac{e^{-4,5}(4,5)^5}{5!} = 0,1708$$

A probabilidade de uma armadilha conter no máximo cinco animais é:

$$P(X \leq 5) = \sum_{x=0}^5 \frac{e^{-4,5}(4,5)^x}{x!} = e^{-4,5} \left[1 + 4,5 + \frac{(4,5)^2}{2!} + \dots + \frac{(4,5)^5}{5!} \right] = 0,7029$$

Exemplos de fenômenos modelados segundo a distribuição de Poisson:

- **Call Center:** Um call center recebe, em média, 5 chamadas por minuto. Podemos usar a distribuição de Poisson para encontrar a probabilidade de receber um determinado número de chamadas em um minuto.
- **Fluxo de Tráfego:** Em média, 2 carros passam por um ponto de verificação a cada 10 minutos. Podemos usar a distribuição de Poisson para encontrar a probabilidade de um determinado número de carros passar pelo ponto de verificação em 10 minutos.
- **Tráfego da web:** Um site recebe, em média, 10 visitas por hora. Podemos usar a distribuição de Poisson para encontrar a probabilidade de receber um determinado número de visitas em uma hora.

Resumo dos modelos para variáveis discretas

Quadro 1. Modelos para variáveis discretas

Modelo	$P(X = x)$	Parâmetros	$E(X)$, $\text{Var}(X)$
Bernoulli	$p^x(1-p)^{1-x}$, $x = 0, 1$	p	p , $p(1-p)$
Binomial	$\binom{n}{x} p^x (1-p)^{n-x}$, $x = 0, \dots, n$	n, p	np , $np(1-p)$
Poisson	$\frac{e^{-\lambda} \lambda^x}{x!}$, $x = 0, 1, \dots$	λ	λ , λ
Geométrica	$p(1-p)^{x-1}$, $x = 1, 2, \dots$	p	$\frac{1}{p}$, $\frac{1-p}{p^2}$
Hipergeométrica	$\frac{\binom{n}{x} \binom{N-n}{n-x}}{\binom{N}{n}}$, $a \leq x \leq b^{(1)}$	N, r, n	$\frac{nr}{N}$, $n \left(\frac{r}{N} \right) \left(1 - \frac{r}{N} \right) \left(\frac{N-n}{N-1} \right)$

$$^{(1)}a = \max(0, n - N + r), b = \min(r, n).$$


Exemplos resolvidos

- Suponha que desejamos calcular a probabilidade de $x = 8$ procedimentos de angioplastia bem-sucedidos em $n = 10$ pacientes com estenose unilateral da artéria renal. A probabilidade de uma angioplastia ser bem sucedida de cada vez é de 70%. Podemos calcular a probabilidade de uma angioplastia ser bem sucedida.

$$P(x) = \frac{10!}{8! 2!} 0,7^8 (1-0,7)^2 = 0,2335$$

Há aproximadamente uma em cada quatro chances de obter oito angioplastias bem-sucedidas em 10 ensaios.

Da mesma forma, qual a probabilidade de, recebendo oito ou mais (ou seja, oito ou nove ou 10), obter procedimentos de angioplastia bem-sucedidos?



Distribuição binomial de probabilidade.

2 Suponha que a incidência de um certo tipo de câncer em uma determinada região é de 250 casos por ano. Qual é a probabilidade de haver exatamente 135 casos de câncer nos próximos 6 meses?

Usando a distribuição de Poisson, podemos calcular

$$P(135 \text{ cancers} \mid \mu = 125) = (e^{-125} 125^{135}) / 135! = 0,0232$$

Portanto, aproximadamente 2,3% de uma chance existe a observação de 135 cânceres nos próximos 6 meses.

Aplicações

1. Uma empresa que fornece computadores pelo correio tem seis linhas telefônicas. Seja X o número de linhas em uso em determinado horário. Suponha que a fmp de X seja conforme a tabela a seguir.

x	0	1	2	3	4	5	6
$p(x)$	0,10	0,15	0,20	0,25	0,20	0,06	0,04

Calcule a probabilidade de cada um dos seguintes eventos.

- {no máximo três linhas estão em uso}
 - {menos de três linhas estão em uso}
 - {pelo menos três linhas estão em uso}
 - {entre duas e cinco linhas, inclusive, estão em uso}
- A probabilidade do pouso de um avião ser bem-sucedido usando um simulador de voo é dada por 0,70. Seis estudantes de pilotagem, escolhidos aleatoriamente e independentemente, são convidados a tentar voar no avião, usando o simulador. Qual a probabilidade de dois dos seis estudantes pousarem com sucesso usando o simulador?
 - Um programa de incentivo à amamentação exclusiva ao seio nos primeiros 3 meses está sendo executado em um hospital universitário. Verificou-se que a eficácia do programa era de $\pi = 60\%$.
Calcule a probabilidade para considerando entre 0 e 20 mães que deram à luz neste hospital e obtenha a distribuição de probabilidade da variável aleatória número de mães amamentando exclusivamente ao seio. Utilize o R para obter a tabela e o gráfico.
 - Suponha que o número médio de acidentes com fogos de artifício ocorridos por ano em uma cidade é de 5 por 100.000 habitantes. Determinar a probabilidade de em uma cidade de 200.000 habitantes haver:
 - zero acidentes
 - dois acidentes
 - mais de dois acidentes
 - Um balde de 5 litros de água é retirado de um pântano. A água contém 75 larvas de mosquitos. Um balde de 200 ml de água é retirado do balde para mais análise. O que é
 - O número esperado de larvas no balde?
 - A probabilidade de o frasco conter pelo menos uma larva de mosquito?

Referências

Bussab, Wilton de Oliveira; Morettin, Pedro Alberto. Estatística básica. 9. ed. São Paulo: Saraiva, 2017.

Devore J L. Probability and Statistics for Engineering and the Sciences. Thomson ed. 5a. ed. 284 p.

Joseph L, Reinhold C. Fundamentals of clinical research for radiologists. Introduction to probability theory and sampling distributions. AJR Am J Roentgenol. 2003 Apr;180(4):917-23.

